Mineração de Séries Temporais para Previsão da Inflação: Arquitetura Híbrida Multivariada e Otimização Bioinspirada de Atributos

Time Series Mining for Inflation Forecasting: Multivariate Hybrid Architecture and Bio-Inspired Feature Optimization

Bruno Protásio[1]
orcid.org/xxxx-xxxx-xxxx-xxxx

Daniel Meneses[1]
orcid.org/xxxx-xxxx-xxxx-xxxx

Marcus Vinicius[1]
orcid.org/xxxx-xxxx-xxxx-xxxx

Vinicyus Emanuel[1]
orcid.org/xxxx-xxxx-xxxx-xxxx

[1]**Escola Politécnica de Pernambuco**, Universidade de Pernambuco (POLI-UPE), Recife, Brasil.

Docente Orientador: Prof. Dr. Alexandre Maciel.

E-mails: xxxx@xxxx.com.

Artigo recebido em: 15/09/2026
Artigo aceito em: 14/10/2026

DOI: 10.xxxx/xxxx

Esta obra apresenta Licença Creative Commons Atribuição-Não Comercial 4.0 Internacional.

Como citar este artigo pela NBR 6023/2018: PROTÁSIO, B.; MENESES, D.; VINICIUS, M.; EMANUEL, V. Mineração de Séries Temporais para Previsão da Inflação: Arquitetura Híbrida Multivariada e Otimização Bioinspirada de Atributos. **Revista de Engenharia e Pesquisa Aplicada**, Recife, v. xx, n. xx, p. xx-xx, 2026. DOI: 10.xxxx/xxxx.

REVISTA DE Engenharia e Pesquisa Aplicada

RESUMO

A dinâmica da inflação no Brasil caracteriza-se por uma complexa interação entre inércia contratual e vulnerabilidade a choques macroeconômicos exógenos. Este trabalho investiga a fronteira preditiva do Índice Nacional de Preços ao Consumidor Amplo (IPCA) sob a ótica da Mineração de Dados e Engenharia da Computação. O objetivo central consiste em desenvolver uma arquitetura híbrida multivariada combinando modelagem autoregressiva linear da inércia estocástica e regressores de *machine learning* alimentados por seleção bioinspirada de atributos (*Feature Selection* via Algoritmos Genéticos e PSO). Na presente etapa, estruturou-se um *pipeline* computacional rigoroso de coleta, saneamento, engenharia de atributos e análise exploratória descritiva de um painel de 29 variáveis macroeconômicas extraídas do Banco Central do Brasil, cobrindo o período de 2012 a 2026 (174 meses contínuos). Os métodos empregados englobam padronização temporal *Month-Start*, saneamento de zeros contábeis estruturais, imputação temporal sem vazamento de dados (*zero data leakage*), codificação trigonométrica da sazonalidade e discretização paramétrica dos regimes inflacionários (Deflação, Meta e Alta). A análise descritiva revelou assimetria positiva (+0,53), concentração da mediana em 0,38% a.m. e presença de cinco *outliers* estruturais associados a choques de oferta e rupturas de cadeias globais de suprimentos. Os resultados estabelecem uma base saneada de alta integridade, fornecendo o arcabouço empírico indispensável para a subsequente calibração dos modelos híbridos e algoritmos de otimização.

PALAVRAS-CHAVE: Mineração de Séries Temporais; Previsão da Inflação; IPCA; Engenharia de Atributos; Econometria Preditiva;

ABSTRACT

Inflation dynamics in Brazil are characterized by a complex interplay between contractual inertia and vulnerability to exogenous macroeconomic shocks. This study investigates the predictive frontier of the Broad National Consumer Price Index (IPCA) from a Data Mining and Computer Engineering perspective. The main objective of the research is to develop a multivariate hybrid predictive architecture combining linear autoregressive modeling of stochastic inertia with machine learning regressors driven by bio-inspired feature selection (Genetic Algorithms and PSO). In this phase, a rigorous computational pipeline was established for data extraction, cleaning, feature engineering, and exploratory descriptive analysis across 29 macroeconomic variables sourced from the Central Bank of Brazil, spanning from 2012 to 2026 (174 continuous months). Implemented methods encompass Month-Start temporal standardization, structural accounting zero cleansing, leakage-free causal imputation (zero data leakage), cyclical trigonometric seasonal encoding, and parametric discretization of inflation regimes (Deflation, Target, and High). Descriptive analysis revealed positive skewness (+0.53), a median concentration of 0.38% per month, and five structural outliers linked to supply shocks and global supply chain disruptions. These findings establish

a sanitized, high-integrity dataset, providing the empirical foundation required for the subsequent calibration of hybrid predictive models and optimization algorithms.

KEY-WORDS: *Time Series Mining; Inflation Forecasting; IPCA; Feature Engineering; Predictive Econometrics;*

DOI: 10.xxxx/xxxx

1 INTRODUÇÃO

A estabilidade de preços constitui o alicerce fundamental do planejamento econômico, da preservação da renda do trabalho e da alocação eficiente de recursos produtivos em economias em desenvolvimento [4, 16]. No Brasil, a trajetória do Índice Nacional de Preços ao Consumidor Amplo (IPCA), calculado mensalmente pelo Instituto Brasileiro de Geografia e Estatística (IBGE), é determinada pela constante fricção entre a persistência inercial dos contratos e a exposição recorrente a choques de oferta exógenos, tais como oscilações cambiais e quebras na cadeia produtiva [5, 10, 14]. A literatura preditiva tradicional apoiou-se predominantemente em formulações autorregressivas univariadas, as quais, embora eficazes na captura da inércia estocástica e da sazonalidade, mostram-se lentas na resposta a descontinuidades e perturbações externas [1, 9]. Em contrapartida, abordagens multivariadas fundamentadas em grandes painéis informacionais enfrentam riscos severos de ruído amostral, multicolinearidade e sobreajuste (*overfitting*) [6, 14].

Diante desse cenário, este projeto de pesquisa tem como objetivo central conceber e validar uma arquitetura híbrida multivariada para a previsão do IPCA, integrando a modelagem da inércia estocástica por processos lineares autorregressivos (ARIMAX) à absorção de choques exógenos residuais não lineares mediante algoritmos de *machine learning* (*Random Forest*) com seleção bioinspirada de atributos (*Feature Selection* via Algoritmos Genéticos e PSO) [7, 8, 11, 18]. A relevância aplicada dessa abordagem estrutura-se em três vertentes diretas [2, 12]:

- **Governança Pública e Macroeconômica:** Redução de assimetrias informacionais para a antecipação de pressões de custos antes de sua disseminação na economia, auxiliando na ancoragem das expectativas dos agentes [2, 3];
- **Mercado Financeiro e Atividade Corporativa:** Apoio tempestivo ao planejamento orçamentário empresarial, gestão de risco de tesouraria e correta precificação de contratos e ativos indexados à inflação (como debêntures e títulos NTN-B) [12, 17];
- **Engenharia da Computação e Mineração de Dados:** Consolidação de um ambiente metodológico rigoroso de mineração em séries temporais complexas, solucionando desafios práticos de sincronização multivariada e prevenção de viés preditivo (*zero data leakage*) [7, 14].

No escopo da presente etapa, o foco consiste na formalização conceitual do problema, na estruturação do protocolo interdisciplinar e na implementação do *pipeline* integral de coleta, saneamento, engenharia de atributos e análise exploratória de um painel de 29 variáveis macroeconômicas oficiais (174 meses contínuos, de 2012 a 2026), preparando a base empírica para as etapas posteriores de otimização e calibração preditiva [6, 10].

1.1 Descrição do Problema

O desafio central de modelagem reside em arbitrar entre a inércia temporal e a sensibilidade a choques macroeconômicos externos [1, 6]:

- **1. A Hipótese Univariada:** Postula que a inércia inflacionária — sustentada por indexação contratual e rigidez de preços — domina a trajetória da série, de modo que modelos autorregressivos simples superariam formulações complexas que demandam estimativas de terceiros [1, 5];
- **2. A Hipótese Multivariada:** Postula que indicadores antecedentes de preços no atacado, custos de transporte, cotação do dólar e nível de atividade agregada emitem sinais preditivos antecipados que o histórico isolado do índice de inflação é incapaz de capturar a tempo [6, 14].

O problema concreto investigado consiste em responder se o enriquecimento do espaço de atributos por meio de séries temporais exógenas selecionadas por algoritmos bioinspirados reduz o erro de generalização em horizontes de 1 a 12 meses à frente em comparação aos modelos clássicos puramente autorregressivos [8, 11, 18].

1.2 Objetivos do Projeto

1.2.1 Objetivo Geral da Etapa Atual

Estruturar o arcabouço computacional e conceitual do projeto, formalizando a parceria com os especialistas de domínio (economistas), delimitando a base de dados longitudinal mensal (2012–2026) e executando o saneamento e a análise descritiva dos atributos [7, 10].

1.2.2 Objetivos Específicos do Escopo Atual

- Definir o protocolo de governança interdisciplinar com os especialistas de domínio econômico [2, 14];
- Coletar e consolidar 29 variáveis macroeconômicas via API oficial do SGS/BACEN (174 observações mensais contínuas) [2, 10];
- Desenvolver e executar rotinas de tratamento de zeros estruturais, sincronização de periodicidades e imputação de valores ausentes sem vazamento de informação temporal (*zero data leakage*) [7, 14];
- Realizar a análise exploratória e descritiva dos atributos numérico (IPCA) e nominal derivado (Regimes de Inflação), caracterizando medidas de tendência central, dispersão, assimetria e presença de *outliers* [7, 10];
- Estruturar o dicionário de dados final da base consolidada pré-processada [2, 15].

1.3 Justificativa Metodológica e Aplicada

Projetos preditivos em econometria aplicada frequentemente falham devido à desconexão entre a sofisticação algorítmica e a realidade operacional das variáveis [6, 12]. A elaboração de um *pipeline* robusto de mineração de dados mitiga riscos de vazamento de dados (*look-ahead bias*), reduz redundâncias colineares e garante que a posterior aplicação de técnicas de inteligência artificial repouse sobre bases empiricamente consistentes [6, 7, 14].

DOI: 10.xxxx/xxxx

1.4 Delimitação do Escopo e Escopo Negativo

Em estrita conformidade com o cronograma metodológico da disciplina de Mineração de Dados da POLI-UPE [7, 15]:

- **Não faz parte desta entrega:** O treinamento, teste, validação cruzada temporal ou ajuste de hiperparâmetros de modelos preditivos (ARIMAX, *Random Forest* ou Redes Neurais) [1, 14, 18];
- **Não faz parte desta entrega:** A execução dos algoritmos bioinspirados de seleção de atributos (Algoritmos Genéticos e Otimização por Enxame de Partículas - PSO) [8, 11];
- **Não faz parte desta entrega:** A comparação de métricas preditivas de acurácia (RMSE, MAE, MAPE) e a disponibilização de interface final para usuários [6, 15].

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Contexto Macroeconômico: Dinâmica da Inflação e Atuação do BACEN

Compreender a dinâmica da inflação requer o conhecimento dos canais econômicos que conectam as decisões de política monetária ao índice de preços ao consumidor [4, 13]:

O que é a Inflação na Prática? A inflação corresponde ao aumento generalizado e contínuo do nível de preços de bens e serviços de uma economia ao longo do tempo, acarretando a perda sistemática do poder aquisitivo da moeda nacional [4, 13].

Como o IPCA Mede Essa Realidade? O IPCA, calculado pelo IBGE desde 1979 e índice oficial do regime de metas desde 1999, afere o consumo pessoal de famílias com rendimento mensal entre 1 e 40 salários mínimos residentes em áreas urbanas de 16 regiões geográficas do país [10]. Sua cesta abrange mais de 400 subitens agrupados em 9 grupos ponderados pela Pesquisa de Orçamentos Familiares (POF) [10].

Os Três Grandes Motores da Inflação: (a) Inflação de Custos, gerada por choques de oferta em insumos básicos e repasse cambial (*pass-through*); (b) Inflação de Demanda, decorrente de pressões em que a demanda agregada suplanta a capacidade produtiva instalada; e (c) Inflação Inercial, sustentada por indexação formal e memória inflacionária pretérita [4, 5, 16].

O Banco Central e a Política Monetária: A dinâmica da inflação conecta-se à arquitetura do Sistema Financeiro Nacional, onde o Conselho Monetário Nacional (CMN) estipula as metas anuais e o Banco Central do Brasil (BACEN) opera a taxa básica de juros (Selic) como mecanismo de estabilização [2, 3]. Quando o índice se desvia do centro da meta, o Comitê de Política Monetária (COPOM) eleva a Selic para desaquecer o consumo [3, 17]. O ponto crítico reside na existência de defasagens temporais de transmissão (*transmission lags*), que demandam entre 6 e 12 meses (dois a quatro trimestres) para produzir efeitos plenos sobre o consumo e investimentos, impondo a necessidade de modelos preditivos tempestivos [3, 17].

2.2 Mineração de Dados em Séries Temporais

A Mineração de Dados em Séries Temporais (*Time Series Data Mining*) visa descobrir padrões estruturais, tendências latentes e dependências dinâmicas em dados sequenciais indexados cronologicamente [7, 9]. Séries macroeconômicas violam a premissa de observações independentes e identicamente distribuídas (i.i.d.), exigindo tratamento rigoroso de estacionariedade, quebras estruturais e ordenação temporal [7, 9].

2.3 Trabalhos Relacionados e Análise de Diferenciais

A literatura contemporânea divide-se em abordagens univariadas clássicas Box-Jenkins [1, 9], vetores autorregressivos VAR/VECM [4] e algoritmos de Machine Learning de alta dimensionalidade [6, 14]. A Tabela 1 sintetiza a matriz comparativa de diferenciais metodológicos.

Tabela 1 - Matriz Comparativa de Trabalhos Relacionados e Diferenciais Metodológicos do Projeto

Dimensão / Critério	Abordagem Univariada (Box-Jenkins) [1]	Modelos Econométricos (VAR / VEC) [4]	Machine Learning Multivariado [6, 14]	Arquitetura Híbrida Proposta (Este Projeto)
Inércia Inflacionária	Ótima (polinômios autorregressivos puros).	Moderada (limitada pelo número de defasagens).	Baixa a moderada (não modela a dependência pura).	**Ótima (componente ARIMAX dedicado à inércia estocástica).**
Choques Não Lineares	Incapaz de modelar quebras estruturais ou choques.	Modela não linearidades endógenas, mas cego a choques.	Captura interações não lineares, negligencia a inércia pura.	**ARIMAX ancora a inércia e a *Random Forest* absorve os choques residuais.**
Espaço de Atributos	Nulo (apenas defasagens da própria série temporal).	Pequeno porte (3 a 6 variáveis para evitar sobreparametrização).	Amplo painel (50 a 100 séries via regularização Lasso/Ridge).	**29 covariáveis selecionadas via Algoritmos Genéticos e PSO bioinspirados.**
Vazamento Temporal	Trivial pela natureza univariada do processo.	Moderada, suscetível a revisões metodológicas de séries.	Crítica: requer validação em janelas expansivas ou deslizantes.	**Protocolo rigoroso de janelas deslizantes (*rolling windows*).**
Interpretabilidade	Alta interpretabilidade estatística formal.	Alta coerência conceitual com funções impulso-resposta.	Caixa-preta (dificuldade de audição por formuladores).	**Alta transparência: decomposição em inércia linear + resíduo não linear.**

Fonte: Elaboração própria com base na revisão de literatura metodológica (2026).

3 MATERIAIS E MÉTODOS

A metodologia adotada para o desenvolvimento deste trabalho articula-se em

DOI: 10.xxxx/xxxx

quatro fases fundamentais, estruturadas sob um fluxo estrito de engenharia de dados e modelagem estatística. A Figura 1 ilustra o fluxograma metodológico global do projeto, evidenciando as etapas executadas no presente marco e as atividades planejadas para a fase subsequente.

Figura 1 – Fluxograma Metodológico do Pipeline de Mineração de Dados



Fonte: Autores (2026).

3.1 Stakeholders Envolvidos

A concepção deste *pipeline* integrou diretamente duas equipes especializadas com papéis complementares: (a) Equipe de Engenharia da Computação / Mineração de Dados da POLI-UPE, responsável pelo desenho da arquitetura computacional, extração automatizada via APIs públicas, higienização, tratamento matemático de valores ausentes, análise descritiva e desenho algorítmico da futura seleção bioinspirada de atributos; e (b) Especialistas de Domínio Econômico (Economistas), responsáveis pela validação conceitual das 29 variáveis macroeconômicas selecionadas, determinação dos canais de transmissão e defasagens da política monetária e parametrização dos regimes inflacionários nominais.

3.2 Descrição da Base de Dados

A base empírica foi extraída diretamente do Sistema Gerenciador de Séries Temporais (SGS) do Banco Central do Brasil [2], agregando fontes oficiais como IBGE, FGV, ANP, EPE e Ministério do Trabalho. O painel contempla 29 variáveis macroeconômicas distribuídas em seis dimensões analíticas: Preços ao Consumidor e Núcleos (IPCA Geral e 8 núcleos setoriais do IBGE), Índices de Custos e Atacado (INPC, IGP-M, IGP-DI, IPC-BR), Câmbio e Finanças (PTAX, Selic, Reservas Internacionais), Nível de Atividade (PIB Mensal, Produção de Ovos), Mercado de Trabalho (Desemprego PNAD Contínua, Salário Mínimo, Estoques de Emprego CAGED) e Energia/Combustíveis (Refino de Petróleo, Consumo de Gasolina e Carga Elétrica Comercial, Residencial e Total).

3.2.1 Delimitação Temporal e Justificativa Metodológica (2012 a 2026)

A delimitação cronológica do estudo compreende o horizonte contínuo de janeiro de 2012 a junho de 2026, totalizando 174 observações mensais contínuas. A definição do marco inicial em 2012 é metodologicamente necessária para assegurar a homogeneidade dos dados, uma vez que o IBGE introduziu naquele ano duas reformas estruturais profundas: a revisão da estrutura de ponderação da cesta do IPCA com base nos microdados da Pesquisa de Orçamentos Familiares (POF 2008-2009) e a substituição definitiva da antiga Pesquisa Mensal de Emprego (PME) pela Pesquisa Nacional por Amostra de Domicílios Contínua (PNAD Contínua).

A tentativa de retroagir a série temporal para períodos anteriores a 2012 introduziria quebras estruturais irreconciliáveis nos indicadores do mercado de trabalho e de desocupação, distorcendo os padrões estatísticos calculados pelos algoritmos de aprendizado. Por sua vez, a extensão do horizonte amostral até meados de 2026 garante a incorporação do ciclo econômico completo pós-pandemia, englobando as tensões inflacionárias decorrentes de gargalos nas cadeias produtivas globais, o choque energético internacional e as recentes flutuações das taxas de juros domésticas.

3.3 Pré-processamento dos Dados

3.3.1 Procedimentos de Limpeza e Saneamento de Dados (Data Cleaning)

Três desafios práticos de engenharia de dados foram solucionados: (a) Sincronização cronológica com padronização no início do mês

DOI: 10.xxxx/xxxx

(*Month-Start* - MS); (b) Tratamento de zeros contábeis estruturais em bases administrativas (CAGED e EPE), convertendo zeros artificiais em dados ausentes (*missing data*); e (c) Imputação temporal causal sem vazamento de informação (*zero data leakage*), aplicando interpolação estritamente retrospectiva (*backward*) sobre dados passados.

3.3.2 Técnicas de Redução de Dados e Engenharia de Atributos

A sazonalidade foi capturada mediante transformações harmônicas contínuas no círculo trigonométrico: mes_sin = sin(2*pi*m/12) e mes_cos = cos(2*pi*m/12), preservando a proximidade cíclica entre dezembro e janeiro sem inflacionar a dimensionalidade com 11 variáveis binárias colineares (*dummies*).

3.3.3 Dicionário de Dados Consolidado Pré-Processado

A base pré-processada consolidada reúne 29 covariáveis e 174 meses contínuos. A Tabela 2 apresenta o dicionário técnico de dados estruturado.

Tabela 2 - Dicionário de Dados da Base Consolidada Pré-Processada (174 Meses, 2012–2026)

Atributo	Código / Fonte	Tipo de Dado	Regra de Pré-processamento	Dimensão	Papel no Modelo Preditivo
IPCA (Geral)	SGS 433 (IBGE)	Float64 (% a.m.)	Sem nulos; sincronização contínua MS	Alvo Principal	Variável dependente contínua (alvo preditivo).
IPCA_Alimentos	SGS 1635 (IBGE)	Float64 (% a.m.)	Sincronização MS; interpolação causal	Preços Setoriais	Covariável exógena - Choques climáticos e safra.
IPCA_Habitacao	SGS 1636 (IBGE)	Float64 (% a.m.)	Alinhamento mensal; verificação de integridade	Preços Setoriais	Covariável exógena - Tarifas reguladas e aluguéis.
IPCA_Transportes	SGS 1639 (IBGE)	Float64 (% a.m.)	Sincronização MS; higienização	Preços Setoriais	Covariável exógena - Sensibilidade a combustíveis.
USDBRL (PTAX)	SGS 3696 (BACEN)	Float64 (R$/US$)	Conversão diária para média mensal útil	Câmbio / Finanças	Covariável exógena - Mecanismo de pass-through cambial.
SELIC	SGS 4390 (BACEN)	Float64 (% a.m.)	Conversão de taxa diária para média mensal útil	Câmbio / Finanças	Covariável exógena - Taxa básica de juros do COPOM.
Reservas_Internac.	SGS 3546 (BACEN)	Float64 (US$ Mi)	Alinhamento mensal MS; saneamento de lacunas	Câmbio / Finanças	Covariável exógena - Liquidez externa e blindagem.
IGP_M	SGS 189 (FGV)	Float64 (% a.m.)	Sincronização MS; alinhamento de competência	Preços Setoriais	Covariável exógena - Indicador antecedente no atacado.
PIB_Mensal	SGS 4380 (BACEN)	Float64 (R$ Mi)	Tratamento de atrasos de divulgação; MS	Atividade Econômica	Covariável exógena - Proxy do nível de atividade agregada.
Desemprego (PNAD)	SGS 24369 (IBGE)	Float64 (% PEA)	Truncamento pós-2012; interpolação causal	Mercado Trabalho	Covariável exógena - Dinâmica da desocupação (Phillips).
Estoque_Empregos	SGS 28763 (CAGED)	Float64 (Mil vínc.)	Zeros tratados como ausentes; interpolação	Mercado Trabalho	Covariável exógena - Saldo mensal de emprego formal.
Consumo_Gasolina	SGS 1393 (ANP)	Float64 (m³)	Sincronização MS; zeros tratados como ausentes	Combustíveis	Covariável exógena - Consumo automotivo e transporte.
Consumo_Energia	SGS 1406 (EPE)	Float64 (MWh)	Sincronização mensal MS; verificação causal	Energia	Covariável exógena - Demanda física global de eletricidade.
Regime de Inflação	IBGE / CMN	Categórico	Discretização: Deflação, Meta e Alta	Governança / CMN	Atributo nominal derivado qualitativo.
mes_sin / mes_cos	Engenharia Temporal	Float64	Harmônicas trigonométricas anuais sin/cos	Sazonalidade	Covariáveis cíclicas contínuas periódicas.

Fonte: Elaboração própria a partir do pipeline desenvolvido e validado com os especialistas de domínio (2026).

3.4 Análise Exploratória e Descritiva dos Dados

3.4.1 Distribuição de Frequências e Métricas Descritivas

Para a variável alvo contínua (IPCA), a série de 174 meses registra: Média mensal de 0,447%; Mediana de 0,380%; Desvio padrão de 0,344%; Mínimo de -0,680% (julho/2022); Máximo de 1,950% (março/2015); Assimetria positiva (+0,53); e Curtose de 3,82 (distribuição leptocúrtica com caudas pesadas).

O atributo nominal derivado (Regime de Inflação) foi discretizado com base nas metas do BACEN em: Deflação (IPCA <= 0%), Meta (0% <

DOI: 10.xxxx/xxxx

IPCA <= 0,55%) e Alta (IPCA > 0,55% a.m.). A Tabela 3 apresenta a distribuição percentual amostral.

Tabela 3 - Distribuição de Frequência do Atributo Nominal (Regime de Inflação)

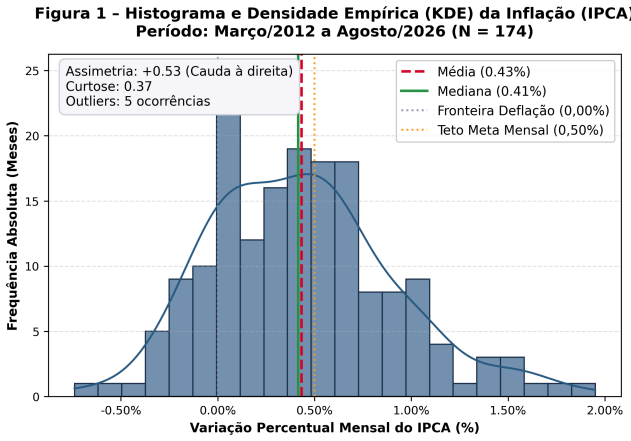
Regime Nominal	Critério Paramétrico	Freq. Abs.	Freq. Rel. (%)
Deflação	IPCA ≤ 0,00%	27	15,52%
Meta	0,00% < IPCA ≤ 0,55%	77	44,25%
Alta	IPCA > 0,55%	70	40,23%
Total	**Amostra Global (2012–2026)**	**174**	**100,00%**

Fonte: Elaboração própria a partir do SGS/BACEN e CMN (2026).

3.4.2 Análise Visual dos Dados

A Figura 2 confirma que a distribuição concentra-se entre 0,10% e 0,60% ao mês. A proximidade entre média e mediana reforça a regularidade central, enquanto a assimetria positiva (+0,53) demonstra que choques inflacionários são significativamente mais severos do que reduções de preços.

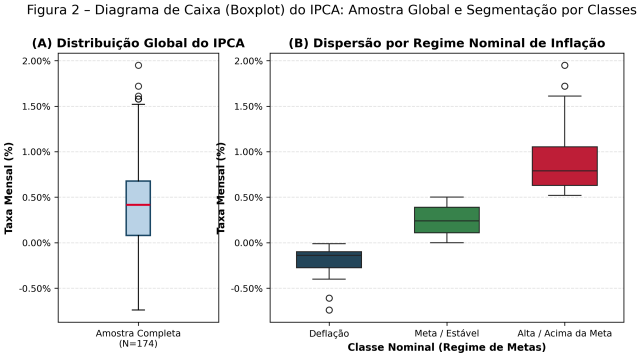
Figura 2 – Histograma e Densidade Empírica (KDE) do IPCA



Fonte: Autores (2026).

O Diagrama de Caixa (*Boxplot*) univariado na Figura 3 identifica 5 *outliers* severos pelo critério de Tukey (IQR): março/2015 (+1,95%), outubro/2020 (+1,72%), novembro/2020 (+1,61%), dezembro/2020 (+1,58%) e dezembro/2021 (+1,58%), decorrentes de choques em carnes e restrições logísticas globais. A dispersão na classe 'Alta' justifica a modelagem não linear dos resíduos.

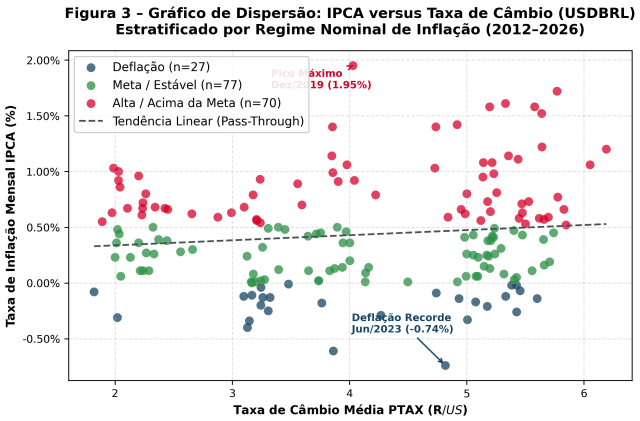
Figura 3 – Diagrama de Caixa (Boxplot) do IPCA Global e por Regimes



Fonte: Autores (2026).

A Figura 4 evidencia a relação positiva entre desvalorização cambial e inflação (*pass-through* cambial). À medida que a cotação do dólar opera em patamares elevados, a incidência de meses no regime de 'Alta' aumenta perceptivelmente.

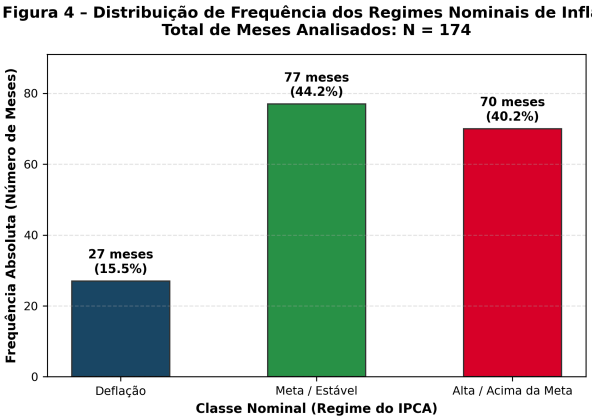
Figura 4 – Dispersão entre IPCA e Câmbio (USDBRL) por Regime



Fonte: Autores (2026).

A Figura 5 sintetiza a distribuição amostral: 44,25% dos meses situaram-se na meta, 40,23% em patamares elevados e 15,52% em deflação (provocada por desonerações tributárias temporárias e contrações severas de demanda).

Figura 5 – Proporção dos Regimes de Inflação (N = 174)



Fonte: Autores (2026).

DOI: 10.xxxx/xxxx

3.4.3 Governança, Integridade e Qualidade

As rotinas de ingestão via API SGS/BACEN contam com validação de tipos, verificação de limites estocásticos e rastreabilidade completa de código, assegurando a reprodutibilidade dos experimentos computacionais.

4 CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS

O presente estudo estruturou com rigor metodológico o *pipeline* de dados para o enfrentamento de um dos mais desafiadores problemas econométricos da economia brasileira: a modelagem e previsão do IPCA. Ao longo de 174 meses contínuos (2012–2026), articulou-se a coleta automatizada de 29 variáveis macroeconômicas oficiais, estabelecendo rotinas robustas de higienização, tratamento de zeros contábeis e imputação causal temporal estrita, imune a vazamentos preditivos (*zero data leakage*).

A análise exploratória descritiva comprovou as propriedades teóricas da série: a presença de assimetria positiva (+0,53) e caudas pesadas com cinco *outliers* históricos acentuados evidencia que a inflação brasileira não pode ser modelada sob premissas gaussianas estritas. Além disso, a categorização em regimes nominais revelou que mais de 40% das observações operaram acima do teto estipulado pelas autoridades monetárias, ratificando a relevância de variáveis de pressão externa (como o câmbio PTAX e combustíveis) para a antecipação de mudanças de regime.

Como desdobramentos imediatos para a próxima etapa do projeto, delineiam-se:

- A implementação dos algoritmos bioinspirados de seleção de atributos (Algoritmos Genéticos e PSO) para identificar a combinação parcimoniosa ótima de variáveis exógenas e defasagens temporais [8, 11];
- A calibração da arquitetura híbrida de previsão: um componente linear ARIMAX para absorver a inércia autorregressiva estocástica, acoplado a um regressor *Random Forest* responsável por capturar as interações não lineares sobre os resíduos [14, 18];
- A avaliação comparativa de acurácia através de janelas temporais deslizantes (*rolling windows*) de 1 a 12 meses à frente frente aos *benchmarks* econométricos clássicos [6, 9].

REFERÊNCIAS

[1] BOX, G. E.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. **Time Series Analysis: Forecasting and Control**. 5. ed. Hoboken: John Wiley & Sons, 2015.

[2] BANCO CENTRAL DO BRASIL (BACEN). **Sistema Gerenciador de Séries Temporais (SGS)**. Brasília: BACEN, 2026. Disponível em: <https://www3.bcb.gov.br/sgspub/>. Acesso em: 16 set. 2026.

[3] BANCO CENTRAL DO BRASIL (BACEN). **Relatório de Inflação**, v. 26, n. 2. Brasília: Banco Central do Brasil, 2024.

[4] BLANCHARD, O. **Macroeconomia**. 7. ed. São Paulo: Pearson, 2017.

[5] BRESSER-PEREIRA, L. C.; NAKANO, Y. **A Teoria da Inflação Inercial**. São Paulo: Brasiliense, 1984.

[6] GARCIA, M. G.; MEDEIROS, M. C.; VASCONCELOS, G. F. Real-time inflation forecasting with high-dimensional data: the case of Brazil. **International Journal of Forecasting**, v. 33, n. 3, p. 679–693, 2017.

[7] HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2. ed. New York: Springer, 2009.

[8] HOLLAND, J. H. **Adaptation in Natural and Artificial Systems**. Cambridge: MIT Press, 1992.

[9] HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting: Principles and Practice**. 3. ed. Melbourne: OTexts, 2021.

[10] INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Sistema Nacional de Índices de Preços ao Consumidor (SNIPC): Metodologia do IPCA e INPC**. Rio de Janeiro: IBGE, 2020.

[11] KENNEDY, J.; EBERHART, R. Particle swarm optimization. In: **Proceedings of ICNN'95 - IEEE International Conference on Neural Networks**, v. 4, p. 1942–1948, 1995.

[12] KHANDANI, A. E.; KIM, A. J.; LO, A. W. Consumer credit-risk models via machine-learning algorithms. **Journal of Banking & Finance**, v. 34, n. 11, p. 2767–2787, 2010.

[13] MANKIW, N. G. **Macroeconomia**. 10. ed. Rio de Janeiro: LTC, 2021.

[14] MEDEIROS, M. C.; VASCONCELOS, G. F.; VEIGA, Á.; ZILBERMAN, E. Forecasting inflation in a data-rich environment: the benefits of machine learning methods. **Journal of Business & Economic Statistics**, v. 39, n. 1, p. 98–119, 2021.

[15] PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

[16] SIMONSEN, M. H. **30 Anos de Indexação**. Rio de Janeiro: Editora FGV, 1995.

[17] TAYLOR, J. B. Discretion versus policy rules in practice. **Carnegie-Rochester Conference Series on Public Policy**, v. 39, p. 195–214, 1993.

[18] ZHANG, G. P. Time series forecasting using a hybrid ARIMA and neural network model. **Neurocomputing**, v. 50, p. 159–175, 2003.

DOI: 10.xxxx/xxxx