

Notas de fala | Clusterização A e B

Acompanham os nove slides da apresentação. Fonte: notebook do projeto.

1. Pergunta do trabalho

Agrupamos 174 meses da economia brasileira sem informar aos algoritmos o IPCA geral nem a classificação de inflação. Depois de formar os grupos, comparamos o resultado com faixas previamente definidas para o IPCA mensal. A pergunta é se os indicadores formam perfis que se relacionam com essas faixas.

2. Dados e experimentos

A base vai de março de 2012 a agosto de 2026. No experimento A entraram 18 variáveis macroeconômicas após retirar duas colunas redundantes. No B entraram seis componentes setoriais do IPCA. Em ambos usamos K-means e hierárquico Ward com variáveis padronizadas. Regime_Inflacao é uma classificação externa: IPCA abaixo de zero, de zero até 0,50%, ou acima de 0,50%. Esses nomes são faixas operacionais mensais, não uma verificação formal da meta oficial.

3. Preparação e PCA de A

A análise de correlação dos níveis e das variações mensais levou à retirada de IGP_M e Consumo_Energia_Total, mantendo IGP_DI e Consumo_Energia_Residencial. O PCA de dois eixos mostra 68,6% da variação dos 18 indicadores. Três componentes capturam 80% e cinco capturam 90%. É essencial dizer que o PCA em duas dimensões serve ao gráfico: a clusterização principal usa as 18 variáveis padronizadas.

4. Escolha de k em A

Testamos k de 2 a 6. Para K-means, k=2 obteve Silhouette 0,408, Calinski-Harabasz 130,854 e Davies-Bouldin 0,969, os melhores valores entre as opções testadas. Ward também favoreceu k=2, com Silhouette 0,400, Calinski-Harabasz 129,323 e Davies-Bouldin 1,008. A inércia sempre cai quando k aumenta; o cotovelo não foi o critério único. No K-means, os grupos têm 121 e 53 meses.

5. Principal achado de A

Os dois algoritmos concordam bastante: ARI de 0,908 entre K-means e Ward. Mas a concordância com Regime_Inflacao é quase nula: ARI 0,015 para K-means e 0,005 para Ward. A linha do tempo mostra o motivo: o cluster 0 cobre todos os meses de 2012 a 2021 e três meses de 2022; o cluster 1 cobre os outros meses de 2022 e todo o período de 2023 a agosto de 2026. A separação acompanha períodos históricos, não as três faixas de inflação. Os perfis descrevem associações, não relações causais.

6. Escolha e visualização de B

No experimento B, os dois primeiros eixos do PCA exibem 44,6% da variação. O gráfico em duas dimensões tem sobreposição, o que não prova que os grupos sejam idênticos nas seis variáveis usadas pelos modelos. K-means ficou com cinco grupos: Silhouette 0,249 e Davies-Bouldin 1,283. Ward ficou com quatro grupos: Silhouette 0,235. O dendrograma mostra como os meses se unem conforme cresce a distância de fusão; ele auxilia a escolha de k, mas não impõe um único corte.

7. Perfis de B

No K-means, o cluster 0 tem 38 meses, transportes em 1,32% e alimentação/bebidas em 1,20%, em média. Desses 38 meses, 32 (84,2%) pertencem à faixa de inflação alta; o IPCA geral médio é 0,910%. O cluster 2 tem 74 meses, com componentes relativamente baixos: 44 meses estáveis, 24 de deflação e seis de alta; IPCA médio 0,104%. O cluster 4 tem 13 meses, educação média de 5,08% e IPCA médio de 0,358%. Os números mostram perfis, sem demonstrar causalidade.

8. Sazonalidade em B

Os 13 meses do cluster 4 são todos fevereiro, de 2013 a 2026, exceto fevereiro de 2021. O setor educação sobe muito nesse grupo. Essa repetição ao longo do calendário é uma descoberta interpretável da clusterização. Mesmo assim, os meses do grupo aparecem em faixas diferentes do IPCA geral: um componente setorial forte não determina sozinho a classificação do índice agregado.

9. Conclusão

A encontrou uma divisão interna consistente entre os dois algoritmos, mas principalmente temporal. B encontrou padrões setoriais mais interpretáveis e associação um pouco maior com Regime_Inflacao: ARI 0,152 no K-means e 0,071 no Ward, contra 0,015 e 0,005 em A. A concordância entre K-means e Ward em B foi ARI 0,609. É preciso lembrar que os componentes de B integram o próprio índice que originou a classificação externa; portanto a comparação não é independente. O trabalho é exploratório: não é previsão, acurácia de classificação nem prova causal.