

Notas de fala - Clusterização simplificada

1. A pergunta do trabalho

Cada registro da base representa um mês da economia brasileira. Clusterizar significa procurar meses parecidos sem entregar ao algoritmo a resposta que desejamos encontrar. Fizemos duas experiências mais fáceis de comparar na apresentação: A usa K-means sobre indicadores macroeconômicos; B usa o hierárquico Ward sobre os componentes do IPCA. A pergunta não é qual modelo prevê melhor a inflação, e sim quais padrões cada conjunto de variáveis revela e se esses padrões têm alguma relação com as faixas de inflação já registradas na base.

2. Dados e ajuste dos modelos

São 174 observações mensais, de março de 2012 a agosto de 2026. No experimento A, separamos as variáveis macroeconômicas do IPCA e retiramos IGP_M e Consumo_Energia_Total por redundância, restando 18 indicadores. No B, usamos os seis componentes setoriais do IPCA; o filtro de correlação não removeu nenhum. Aplicamos StandardScaler separadamente em cada base: isso coloca as variáveis na mesma escala para que unidades maiores não dominem as distâncias. Testamos k de 2 a 6 pela Silhouette e ajustamos cada modelo nos 174 meses. Como é uma análise não supervisionada e descritiva, não houve divisão treino/teste nem cálculo de acurácia.

3. Experimento A: escolha do K-means

No A, a Silhouette foi máxima em k=2: 0,408. Ela mede, em termos simples, se cada mês ficou mais próximo do próprio grupo do que dos outros grupos. É uma medida interna de separação; não é acurácia diante do rótulo. Ajustamos KMeans com n_clusters=2, n_init=50 e random_state=42, usando as 18 variáveis padronizadas. Surgiram dois clusters, com 121 e 53 meses. O gráfico PCA reduz o desenho a dois eixos para permitir visualização; esses eixos mostram 68,6% da variação, mas não foram as únicas entradas do K-means.

4. Experimento A: interpretação dos resultados

Na linha do tempo, o cluster 0 reúne todos os meses de 2012 a 2021 e três meses de 2022; o cluster 1 reúne os demais meses até agosto de 2026. Portanto, o principal padrão encontrado é temporal. Quando olhamos o rótulo `Regime_Inflacao` somente depois do ajuste, o ARI é 0,015, valor muito próximo de zero. ARI compara duas divisões sem depender dos números atribuídos aos clusters: 1 seria concordância perfeita, zero indica concordância semelhante à esperada ao acaso. O resultado mostra que a divisão do K-means não reproduziu bem as três faixas de inflação.

5. Experimento B: escolha do Ward

Em B, o método hierárquico começa com cada mês separado e vai fundindo os meses ou grupos mais semelhantes; o dendrograma ilustra essa sequência. Usamos distância euclidiana e ligação Ward nos seis componentes do IPCA depois de padronizá-los. Testamos de dois a seis grupos, e a Silhouette mais alta foi 0,235 em $k=4$. Por isso cortamos a hierarquia em quatro clusters: 37, 95, 13 e 29 meses. O PCA que aparece no notebook é uma visualização, não uma etapa usada para ajustar Ward.

6. Experimento B: perfis encontrados

As médias ajudam a dar sentido aos quatro grupos. No cluster 0, de 37 meses, transportes (1,070%) e alimentação/bebidas (1,287%) têm médias altas; o IPCA geral médio é 0,932%. O cluster 1, com 95 meses, reúne componentes relativamente mais baixos e IPCA médio de 0,223%. O cluster 2 tem 13 meses, todos em fevereiro entre 2013 e 2026, exceto 2021; a média de educação é 5,084% e a do IPCA geral, 0,358%. O cluster 3 tem 29 meses e médias mais altas em saúde/cuidados pessoais e alimentação. O padrão de fevereiro é uma descoberta sazonal clara, mas não demonstra que educação causou o IPCA observado.

7. A classificação que já existia na base

Regime_Inflacao já estava em cada linha da base antes deste trabalho. É a nossa 'cola' para interpretar os grupos, mas não entra nas variáveis de A nem de B. O rótulo tem três categorias: Deflação para IPCA mensal menor que 0%, com 27 meses; Meta / Estável para valores de 0% até 0,50%, inclusive, com 77 meses; e Alta / Acima da Meta para valores superiores a 0,50%, com 70 meses. As porcentagens são 15,5%, 44,3% e 40,2% dos 174 meses, respectivamente. Esses nomes são operacionais: a meta oficial de inflação não é avaliada por esse corte simples do IPCA mensal.

8. A 'cola': grupos cruzados com o rótulo

A tabela cruza cada cluster com as três faixas originais, independentemente dos números dados pelo algoritmo. Em A, o cluster 0 tem 16 meses de deflação, 51 estáveis e 54 de alta; o cluster 1 tem 11, 26 e 16. Os dois misturam as faixas. Em B, o cluster 0 tem 30 meses de alta entre 37, ou 81,1%, e nenhum mês de deflação. O cluster 1 tem 50 estáveis, 24 de deflação e 21 de alta. O cluster 2, apesar de reunir os fevereiroiros, contém 2 de deflação, 6 estáveis e 5 de alta; sazonalidade setorial não equivale a uma mesma faixa de IPCA geral. O cluster 3 está dividido entre 14 estáveis e 14 de alta, com um mês de deflação.

9. Conclusão e comparação cuidadosa

A referência tem três faixas; A encontrou dois clusters e B encontrou quatro. O ARI de B com o rótulo é 0,071, um pouco acima do 0,015 de A: B ficou relativamente mais próximo da classificação já existente, mas ambos os valores são baixos. Em contrapartida, a Silhouette de A foi maior, 0,408 contra 0,235, mostrando grupos mais separados dentro do respectivo conjunto de variáveis. Isso não permite dizer que K-means é superior a Ward, porque cada método recebeu entradas diferentes e formou um número diferente de grupos. A capturou períodos da série; B revelou perfis setoriais e um padrão recorrente em fevereiro. Como os componentes de B fazem parte do índice que gerou o rótulo, essa comparação não é independente. Não devemos chamar os resultados de previsão, acurácia ou prova de causalidade.